

## Tasca S3.01

# Introducció a BigQuery i SQL al Núvol

Benvingut al núvol. En aquest sprint, faràs el salt de treballar en local (MySQL) a treballar amb Google BigQuery, un Data Warehouse serverless dissenyat per a l'anàlisi de dades a gran escala.

En l'entorn empresarial actual, l'analista no acostuma a crear bases de dades des de zero, sinó que ha de connectar-se a repositoris existents (Data Lakes), comprendre els costos del núvol i preparar les dades brutes per a l'anàlisi (ELT).

# Nivell 1: Entorn i Ingesta Híbrida (Code-First)

Escenari:

Acabeu d'arribar a l'empresa. L'equip d'**Enginyeria de Dades** ha deixat els fitxers històrics al **Data Lake** corporatiu.

La teva primera missió és dissenyar i crear l'entorn de treball. El **CTO** (Chief Technology Officer) exigeix professionalitat: no bolcarem dades sense ordre, sinó que implementarem una **Arquitectura Medallion**.

# Exercici 1: Arquitectura de Dades (Lògica vs. Física)

Abans de tocar la consola, has d'entendre la diferència entre allò que dissenyem i allò que construïm:

- » **Arquitectura Lògica (Capes de Dades)**: És el disseny conceptual. Organitza les dades segons el seu nivell de qualitat (Bronze, Silver, Gold).
- » **Implementació Física (Datasets)**: És el recurs real a Google Cloud. A BigQuery, utilitzarem Datasets (contenidors) per materialitzar físicament aquestes capes lògiques.



Tasques:

- Implementareu físicament l'arquitectura lògica creant tres **Datasets** dins d'un mateix **projecte** per centralitzar la facturació i els permisos.
- Per demostrar el teu domini total de la **plataforma**, crearàs cadascun dels datasets utilitzant un mètode diferent.
- Tingueu en compte la **ubicació** de les dades originals per decidir la ubicació física dels tres Datasets.
- Encara que siguin capes lògiques diferents, físicament han de viure a la mateixa **regió** per poder "parlar" entre elles sense costos de transferència.

Crea un Nou Projecte a Google Cloud anomenat:

- sprint3-analytics-[el-teu-nom].

Ho pots crear per la UI, però si ho fas per Consola (gcloud CLI) té un plus.

```
rosercarrera13@cloudshell:~$ gcloud projects create sprint3-analytics-rcarrera1
Create in progress for [https://cloudresourcemanager.googleapis.com/v1/projects/sprint3-analytics-rcarrera1].
Waiting for [operations/create_project.global.6280214238836248551] to finish...done.
Enabling service [cloudapis.googleapis.com] on project [sprint3-analytics-rcarrera1]...
Operation "operations/acat.p2-582480220813-5238e280-0dba-4eea-951c-2dccc5005958" finished successfully.
rosercarrera13@cloudshell:~$
```

**Observacions:** hem utilitzat la terminal de **Cloud Shell** per crear el projecte amb la següent instrucció:  
**gcloud projects create sprint3-analytics-rcarrera1**

**Google Cloud Shell** és una terminal de Linux a la qual podem accedir des de la consola de **Google Cloud**. Ens permet gestionar els recursos del núvol a través de línies de comandes. Disposa de diverses utilitats instal·lades, disponibles i autenticades com per exemple el paquet **Google Cloud CLI** que conté les següents comandes:

- **gcloud:** eina per gestionar serveis generals de **Google Cloud** com configurar la seguretat, gestionar usuaris...
- **gsutil:** eina per gestionar carpetes i fitxers de **Google Cloud Storage**.
- **bk:** eina per treballar amb **BigQuery**. Permet crear datasets, esborrar taules, executar consultes SQL...

En el nostre cas hem utilitzat **gcloud** ja que els projectes són comuns a tota la plataforma de **Google Cloud**.

- » Dataset Físic sprint3\_bronze → Capa Lògica Bronze (Dades Crues)
  - Funció: Dades crues tal com arriben de la font.
  - Mètode: Utilitza la Interfície Gràfica (UI) de BigQuery (fent clics).

Crear un conjunto de datos

ID del proyecto \*  
sprint3-analytics-rcarrera1 [Cambiar](#)

ID de conjunto de datos \*  
sprint3\_bronze

Puede incluir letras, números y guiones bajos

Ubicación de los datos  
EU (múltiples regiones en la Unión Europea) ▼ ⓘ

Conjunto de datos externo

The selected region supports the following external dataset types: Cloud Spanner

☐ Vínculo a un conjunto de datos externo ⓘ

Etiquetas ▼

Opciones avanzadas ▼

[Crear conjunto de datos](#) [Cancelar](#)

**Observacions:** l'entorn de treball de **BigQuery Studio** ens proporciona la possibilitat de gestionar el **Data Warehouse** utilitzant la **Interfície Gràfica (UI)**. Podem crear, modificar i esborrar datasets i taules, carregar dades...

- » Dataset Físic sprint3\_silver → Capa Lògica Silver (Dades Netes)
  - Funció: Dades netes, tipades i deduplicades.
  - Mètode: Utilitza codi SQL (CREATE SCHEMA).

```
1
2 CREATE SCHEMA `sprint3-analytics-rcarrera1.sprint3_silver`
3 OPTIONS (
4   location = 'eu',
5   description = 'sprint3 silver'
6 );
7
```

Se completó la consulta

Resultados de la consulta

Chat

Guardar los res

Información del trabajo

**Resultados**

Detalles de la ejecución

Gráfico de ejecución



Se creó el conjunto de datos llamado sprint3\_silver.

**Observacions:** l'entorn de treball de **BigQuery Studio** també ens dóna la possibilitat de gestionar les dades utilitzant codi SQL a través del **SQL Workspace** .

- » Dataset Físic sprint3\_gold → Capa Lògica Gold (Dades de Negoci)
  - Funció: Dades agregades llestes per a informes i panells de control (dashboards).
  - Mètode: Utilitza Cloud Shell (Línia d'ordres bq).


```
rosercarrera13@cloudshell:~ (sprint3-analytics-rcarrera1)$ bq mk --location=EU sprint3_gold  
Dataset 'sprint3-analytics-rcarrera1:sprint3_gold' successfully created.  
rosercarrera13@cloudshell:~ (sprint3-analytics-rcarrera1)$
```

**Observacions:** hem utilitzat la terminal de **Cloud Shell** per crear el dataset amb la següent instrucció:

**bq mk - - location=EU sprint3\_gold**

En aquest cas utilitzem la línia d'ordres **bq** ja que la creació d'un **dataset** és una operació específica de **BigQuery**.

## » Situació final del projecte



**Observacions:** hem creat els tres datasets a la **regió EU** ja que és la mateixa regió del **bucket** de **Google Cloud Storage** on tenim les dades (**bootcamp-data-analytics-public**). Així evitarem errors en consultar les dades.

## Exercici 2: Ingesta en Capa Bronze (Connexió DDL)

Un analista professional automatitza les tasques. Ara que tens la teva arquitectura a punt, poblarem la primera capa (Bronze) sense moure les dades originals, creant **Taules Externes** que apuntin al **Data Lake**.



Tasca:

Escriu i executa les sentències **CREATE EXTERNAL TABLE** per connectar els següents fitxers al **dataset sprint3\_bronze**. Para molta atenció a les "Notes Tècniques", ja que no tots els arxius tenen el mateix format.



Entrega:

El codi SQL utilitzat per a **transactions\_raw** i una captura de pantalla amb les 5 taules creades.

## » Informació tècnica per a crear les taules externes.

| Taula                     | Domini | Ruta al Núvol (URI)                                        | Notes Tècniques                                                                 |
|---------------------------|--------|------------------------------------------------------------|---------------------------------------------------------------------------------|
| <u>transactions_raw</u>   | ERP    | gs://bootcamp-data-analytics-public/ERP/transactions.csv   | Delimitador: ; (Punt i coma)                                                    |
| companies_raw             | ERP    | gs://bootcamp-data-analytics-public/ERP/companies.csv      | Capçalera: Ignora la 1a fila. Defineix l'esquema manualment perquè tot és text. |
| <u>american_users_raw</u> | CRM    | gs://bootcamp-data-analytics-public/CRM/american_users.csv | Estàndard.                                                                      |
| <u>euopean_users_raw</u>  | CRM    | gs://bootcamp-data-analytics-public/CRM/euopean_users.csv  | Estàndard.                                                                      |
| <u>credit_cards_raw</u>   | CRM    | gs://bootcamp-data-analytics-public/CRM/credit_cards.csv   | Estàndard.                                                                      |

**Observacions:** en aquesta graella tenim la informació necessària per crear les taules externes:

- **Taula:** nom de la taula que hem de crear al dataset **sprint3\_bronze**.
- **Ruta (URI):** ruta on hi ha els fitxers. Com que la ruta comença per **gs://** vol dir que tenim els fitxers a **Google Cloud Storage** que és el servei d'emmagatzematge de fitxers de **Google Cloud**.
- **Notes Tècniques:** especificacions a tenir en compte.

### » CREACIÓ DE LA TAULA EXTERNA TRANSACTIONS\_RAW.

```
1 CREATE OR REPLACE EXTERNAL TABLE `sprint3_bronze.transactions_raw`  
2 OPTIONS (  
3   format = 'CSV',  
4   uris = ['gs://bootcamp-data-analytics-public/ERP/transactions.csv'],  
5   field_delimiter = ',';  
6 );
```

Se completó la consulta

Resultados de la consulta

Chat

Información del trabajo

**Resultados**

Detalles de la ejecución


Gráfico de ejecución

**i** Esta declaración creó una nueva tabla con el nombre transactions\_raw.

**Observacions:** utilitzem la instrucció **CREATE OR REPLACE** per tal que no ens doni error si executem el codi més d'una vegada. A més si ens cal modificar una taula ens estalviem d'esborrar-la abans. A la capa Bronze és habitual de refrescar les dades sovint. Opcions de creació:

- **format:** indiquem que l'origen de les dades és en format .csv.
- **uris:** ruta on es troba el fitxer origen.
- **field\_delimiter:** per indicar que en el fitxer els diferents camps estan separats per punt i coma.

## » COMPROVACIÓ DE LA TAULA TRANSACTIONS\_RAW.




The screenshot shows the Google Cloud BigQuery interface for the 'transactions\_raw' table. The breadcrumb navigation at the top indicates the path: sprint3-analytics-rcarrera1 / Datasets / sprint3\_bronze / Tables / transactions\_raw. Below the navigation bar, there are tabs for 'Esquema' (Schema), 'Detalles', 'Estadísticas', 'Linaje', 'Perfil de datos', and 'Calidad de los datos'. The 'Esquema' tab is selected, displaying a table with 7 columns: 'Nombre del campo', 'Tipo', 'Modo', 'Descripción', 'Clave', and 'Intercalación'. Each row represents a field in the table schema, with checkboxes in the first column for selection.

| <input type="checkbox"/> | Nombre del campo | Tipo      | Modo     | Descripción | Clave | Intercalación |
|--------------------------|------------------|-----------|----------|-------------|-------|---------------|
| <input type="checkbox"/> | id               | STRING    | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | card_id          | STRING    | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | business_id      | STRING    | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | timestamp        | TIMESTAMP | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | amount           | FLOAT     | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | declined         | INTEGER   | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | product_ids      | STRING    | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | user_id          | INTEGER   | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | lat              | FLOAT     | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | longitude        | FLOAT     | NULLABLE | -           | -     | -             |

**Observacions:** comprovem que s'ha creat correctament la taula revisant l'esquema de **transactions\_raw**. A BigQuery l'**esquema** defineix l'estructura de les dades: noms dels camps, tipus de dades i mode. Veiem que s'han creat correctament els camps. Per fer una previsualització de les dades hauríem de fer una consulta SQL i això tindria un cost. Cal valorar si és necessari fer-la.

## » SITUACIÓ FINAL DEL DATASET SPRINT3\_BRONZE



**Observacions:** hem creat cinc **taules externes**. Això vol dir que tenim la definició de la taula a **BigQuery** però les dades estan físicament a **Google Cloud Storage**. Cada vegada que fem una consulta sobre aquestes taules el motor de BigQuery ha de viatjar per la xarxa interna de Google fins a trobar el fitxer i descarregar-lo. Això implica més temps.

## Exercici 3: Càrrega de Dades Locals (Upload)

Falta el catàleg de **Productes**. Aquesta informació no és al **Data Lake**, utilitza el fitxer **products.csv** de l'sprint 2.

- » Carrega aquest fitxer manualment ("Upload") al dataset **sprint3\_bronze** i crea la taula **products\_raw**.
- » Observa que aquesta serà l'única **Taula Nativa** de moment.

## » CREACIÓ DE LA TAULA NATIVA PRODUCTS\_RAW

### Crear tabla

#### Fuente

Create table from  
Subir

Seleccionar archivo \*  
ERP\_products.csv

Formato del archivo  
CSV

#### Destino

Proyecto \*  
sprint3-analytics-rcarrera1

Conjunto de datos \*  
sprint3\_bronze

Tabla \*  
products\_raw

El tamaño máximo del nombre es de 1,024 bytes UTF-8. Se permiten letras, signos, números, conectores, guiones y espacios Unicode.

Tipo de tabla  
Tabla nativa

#### Esquema

☒ Detección automática



El esquema se generará automáticamente.

**Observacions:** estem creant una **taula nativa**, per tant les dades es guarden físicament a BigQuery. Això implica que les consultes sobre aquesta taula seran més **ràpides i eficients** que les consultes sobre taules externes.

En marcar el flag de “**Detección automática**” BigQuery llegeix la capçalera del fitxer csv i assigna els noms dels camps i els tipus de dades de manera automàtica.

## » COMPROVACIÓ DE LES DADES

sprint3-analytics-rcarrera1 / Datasets / sprint3\_bronze / Tables / **products\_raw**

☆ products\_raw   Consulta   Chat   Abrir en   Compartir   Copiar   Instantánea   Borrar   

Esquema   Detalles   Vista previa   Explorador de tablas   **Vista previa**   Estadísticas   Linaje   Perfil de datos   Calidad de los datos

| Fila | id | product_name            | price  | colour  | weight | warehouse_id | category | brand       | cost  | launch_date |
|------|----|-------------------------|--------|---------|--------|--------------|----------|-------------|-------|-------------|
| 1    | 48 | rock Renly in           | 21.53  | #9e9e9e | 2.1    | WH-43        | Beauty   | Bloom       | 7.38  | 2014-07-24  |
| 2    | 18 | Karstark warden         | 148.91 | #c4c4c4 | 0.8    | WH-13        | Beauty   | CareLab     | 47.62 | 2013-07-11  |
| 3    | 90 | Winterfell              | 39.73  | #757575 | 0.8    | WH-85        | Beauty   | CareLab     | 16.58 | 2013-11-01  |
| 4    | 96 | dooku solo              | 20.92  | #282828 | 2.1    | WH-91        | Beauty   | CareLab     | 8.75  | 2013-09-21  |
| 5    | 97 | jinn Winterfell         | 65.25  | #bababa | 1.0    | WH-92        | Beauty   | CareLab     | 26.25 | 2013-02-22  |
| 6    | 25 | skywalker ewok          | 157.53 | #2b2b2b | 1.0    | WH-20        | Beauty   | Luma Skin   | 53.56 | 2014-04-22  |
| 7    | 28 | chewbacca mustafar      | 127.44 | #efefef | 3.0    | WH-23        | Beauty   | Luma Skin   | 45.65 | 2014-06-02  |
| 8    | 42 | sith                    | 83.51  | #494949 | 0.8    | WH-37        | Beauty   | Luma Skin   | 27.23 | 2013-06-10  |
| 9    | 66 | mustafar jinn           | 2.12   | #545454 | 0.8    | WH-61        | Books    | Atlas Books | 1.1   | 2014-02-12  |
| 10   | 9  | Winterfell              | 76.4   | #b5b5b5 | 1.2    | WH-4         | Books    | Campus Read | 40.42 | 2013-08-14  |
| 11   | 31 | Lannister               | 85.02  | #3f3f3f | 0.6    | WH-26        | Books    | Campus Read | 57.38 | 2013-10-07  |
| 12   | 4  | warden south duel       | 71.89  | #111111 | 3.0    | WH-1         | Books    | NorthPress  | 39.17 | 2013-12-31  |
| 13   | 49 | the giantsblood maester | 53.31  | #e2e2e2 | 1.0    | WH-44        | Books    | NorthPress  | 33.64 | 2013-11-19  |
| 14   | 55 | Tully maester           | 3.83   | #6d6d6d | 0.6    | WH-50        | Books    | NorthPress  | 2.49  | 2013-06-04  |

**Observacions:** com que és una taula nativa podem fer una **Vista Prèvia** de la taula per comprovar que les dades s'han carregat correctament sense haver de fer una consulta SQL i per tant **sense cost** afegit.

# Exercici 4: Arquitectura i Rendiment.

## Materialització de Dades (Assistit per IA)

Escenari:

Les consultes sobre el **Data Lake** van lentes. Has de demostrar al teu mànager la diferència de rendiment entre treballar amb **fitxers externs** i treballar amb **taules natives** de **BigQuery**.



Tasques:

- a) Materialització de Dades (Assistit per IA)
- b) Auditoria de Costos
- c) El perill del LIMIT

## a) Materialització de Dades (Assistit per IA)



Tasca:

Crea una nova taula anomenada **sprint3\_bronze.transactions\_raw\_native** que sigui una còpia exacta de la teva taula externa **transactions\_raw**.

Requisit de "AI-Pair Programming":

No escriguis el codi SQL manualment. Utilitza l'**Assistent d'IA** (Gemini) integrat a **BigQuery** (o el xat lateral) per generar la sentència.

👉 El Teu Rol: Ets el responsable de validar que el codi que et dona la IA és correcte abans d'executar-lo.

👉 Entrega:

Una captura de pantalla on es vegi:

- » El prompt que vas escriure a la IA.
- » El codi SQL que la IA va generar.
- » El resultat de l'execució ("This statement created a new table...").

## » CREACIÓ DE LA TAULA TRANSACTIONS\_RAW\_NATIVE

### Prompt utilitzat:

✍ Generar SQL con Gemini

Write a SQL query to create a new table called transactions\_raw\_native in the sprint3\_bronze dataset. It should contain all data from the transactions\_raw table. Please use CREATE OR REPLACE TABLE so I don't get errors if I run it more than once.

📄 Las sugerencias de instrucciones no están disponibles. [Learn more](#)

Generar

### Codi SQL generat:

✍ Generar SQL con Gemini

Write a SQL query to create a new table called transactions\_raw\_native in the sprint3\_bronze dataset. It should contain all data from the transactions\_raw table. Please use CREATE OR REPLACE TABLE so I don't get errors if I run it more than once.

Editar

```
CREATE OR REPLACE TABLE
`sprint3-analytics-rcarrera1`.`sprint3_bronze`.`transactions_raw_native` AS
SELECT
  id,
  card_id,
  business_id,
  timestamp,
  amount,
  declined,
  product_ids,
  user_id,
  lat,
  longitude
FROM
`sprint3-analytics-rcarrera1`.`sprint3_bronze`.`transactions_raw`;
```

✅ Esta consulta procesará 0 B cuando se ejecute.

< 1/1 >

Refine

 [Editar fuentes de la tabla](#)  [Resumen de consulta](#) [Usar la consulta con precaución](#)

Califica esta sugerencia   

Insertar

## » CREACIÓ DE LA TAULA TRANSACTIONS\_RAW\_NATIVE

### Resultat de l'execució del codi SQL generat per IA:

```
1  -- Write a SQL query to create a new table called transactions_raw_native in the sprint3_bronze dataset. It should contain all data from the
   transactions_raw table. Please use CREATE OR REPLACE TABLE so I don't get errors if I run it more than once.
2
3  CREATE OR REPLACE TABLE
4    `sprint3-analytics-rcarrera1`.`sprint3_bronze`.`transactions_raw_native` AS
5  SELECT
6    id,
7    card_id,
8    business_id,
9    timestamp,
10   amount,
11   declined,
12   product_ids,
13   user_id,
14   lat,
15   longitude
16  FROM
17    `sprint3-analytics-rcarrera1`.`sprint3_bronze`.`transactions_raw`;
```

Se completó la consulta

### Resultados de la consulta

[Chat](#)[Guardar los resultados ▼](#)[Abrir en ▼](#)[Información del trabajo](#)[Resultados](#)[Detalles de la ejecución](#)[Gráfico de ejecución](#)

Esta declaración creó una nueva tabla con el nombre transactions\_raw\_native.

[Ir a la tabla](#)

# » VISTA PRÈVIA DE LA TAULA TRANSACTIONS\_RAW\_NATIVE

sprint3-analytics-rcarrera1 / Datasets / sprint3\_bronze / Tables / transactions\_raw\_native

☆ transactions\_r...

🔍 Consulta

💬 Chat

Abrir en ▾

+👤 Compartir ▾

📄 Copiar

📌 Instantánea

🗑️ Borrar

⬆️

↺

Esquema Detalles Vista previa Explorador de tablas Vista previa Estadísticas Linaje Perfil de datos Calidad de los datos

| Fila | id                             | card_id  | business... | timestamp               | amount | declined | product_ids    | user_id | lat           | longitude      |
|------|--------------------------------|----------|-------------|-------------------------|--------|----------|----------------|---------|---------------|----------------|
| 1    | F3E47D02-CE43-4B87-8C3F-5B...  | CcU-4856 | b-2286      | 2015-11-04 13:01:34 UTC | 322.53 | 0        | 40, 47, 56     | 1       | 40.7075479... | -74.0159698... |
| 2    | 97693F29-668B-4289-8E37-023... | CcU-4856 | b-2422      | 2015-12-20 18:06:59 UTC | 161.33 | 0        | 76, 87         | 1       | 40.7092072... | -74.0042491... |
| 3    | 55985941-32AF-490C-BD5A-30...  | CcU-4856 | b-2390      | 2020-06-12 19:22:27 UTC | 535.45 | 0        | 64, 74, 52, 22 | 1       | 40.7064969... | -74.0081135... |
| 4    | BEE02A09-493E-453D-A0C6-FD...  | CcU-4856 | b-2526      | 2023-12-03 19:53:30 UTC | 234.13 | 0        | 26, 14, 70, 37 | 1       | 40.7033855... | -73.9970408... |
| 5    | 70C3BE45-B922-470B-B7CF-EC...  | CcU-4856 | b-2494      | 2018-02-12 18:09:59 UTC | 442.23 | 0        | 74, 53, 85, 42 | 1       | 40.7183569... | -74.0109240... |
| 6    | 78C7704E-F5D1-460C-95BF-DB...  | CcU-4856 | b-2334      | 2020-11-02 01:02:53 UTC | 294.36 | 0        | 99, 80, 34     | 1       | 40.7164815... | -74.0119302... |
| 7    | 3F2720A9-C1C9-4D9B-9FFD-C8...  | CcU-4856 | b-2390      | 2020-08-20 16:55:54 UTC | 189.72 | 0        | 81, 94, 65     | 1       | 40.7132717... | -74.0044826... |
| 8    | 8FA78D29-6180-439E-ADA1-F7...  | CcU-4856 | b-2534      | 2021-11-30 02:22:55 UTC | 298.56 | 0        | 22, 55, 95, 53 | 1       | 40.7052669... | -74.0026638... |
| 9    | 923E634C-2052-4072-A9F4-0E...  | CcU-4856 | b-2562      | 2019-04-11 02:43:55 UTC | 330.7  | 0        | 7, 51, 36, 41  | 1       | 40.7218733... | -73.9965615... |
| 10   | 7A7C6A7C-BA53-4D5C-9A74-9...   | CcU-4856 | b-2490      | 2018-10-21 04:49:45 UTC | 267.57 | 0        | 100, 64, 52    | 1       | 40.7196930... | -74.0021011... |
| 11   | 7E438CE2-B3E0-4C8C-9EA7-0D...  | CcU-4856 | b-2530      | 2018-06-15 18:33:31 UTC | 554.76 | 0        | 67, 20, 23, 21 | 1       | 40.7139257... | -73.9981356... |
| 12   | 7DCC175C-4ACA-47EB-9F7D-3...   | CcU-4856 | b-2494      | 2019-03-04 13:48:19 UTC | 277.83 | 0        | 26, 20, 79     | 1       | 40.7093088... | -74.0115485... |

## b) Auditoria de Costos



Tasca:

Dissenyar una prova per comparar el cost de llegir una sola columna (ex: id) a la taula externa vs. la taula nativa. Utilitza els **Bytes processats** i els **Bytes facturats** per fer la comparació.

- » Quant "pesa" la consulta a **transactions\_raw**?
- » Quant "pesa" la mateixa consulta a **transactions\_raw\_native**?



Entrega:

Captures del validador mostrant la diferència i una conclusió tècnica.

## » CONSULTA A TRANSACTIONS\_RAW

```
1
2 SELECT id FROM `sprint3-analytics-rcarrera1.sprint3_bronze.transactions_raw`;
```

✓ Se completó la consulta

Resultados de la consulta [Chat](#) [Guardar los resultados](#) ▾

[Información del trabajo](#) Resultados Visualización JSON Detalles de la ejecución Gráfico de ejecución

|                                                     |                                                                                                             |
|-----------------------------------------------------|-------------------------------------------------------------------------------------------------------------|
| ID de trabajo                                       | sprint3-analytics-rcarrera1:EU.bquxjob_795e0140_19e96e52616 ( <a href="#">Ver detalles de rendimiento</a> ) |
| Usuario                                             | rosercarrera13@gmail.com                                                                                    |
| Ubicación                                           | EU                                                                                                          |
| Hora de creación                                    | 5 jun 2026, 10:27:41 a.m. UTC+2                                                                             |
| Hora de inicio                                      | 5 jun 2026, 10:27:41 a.m. UTC+2                                                                             |
| Hora de finalización                                | 5 jun 2026, 10:27:43 a.m. UTC+2                                                                             |
| Duración                                            | 2 s                                                                                                         |
| Bytes procesados                                    | 12.61 MB                                                                                                    |
| Bytes facturados                                    | 13 MB                                                                                                       |
| Milisegundos de ranura                              | 1304                                                                                                        |
| Prioridad del trabajo                               | INTERACTIVE                                                                                                 |
| Usar SQL heredado                                   | false                                                                                                       |
| Tabla de destino                                    | <a href="#">Tabla temporal</a>                                                                              |
| Motivos por los que no se usó la caché de metadatos | METADATA_CACHING_NOT_ENABLED: sprint3-analytics-rcarrera1.sprint3_bronze.transactions_raw                   |
| Etiquetas                                           |                                                                                                             |

**Observacions:** fem la consulta d'un camp sobre la **taula externa** i observem que es processen 12,61 MB. Veiem també que en facturar s'arrodoneixen els Bytes processats.

## » CONSULTA A TRANSACTIONS\_RAW\_NATIVE

2

```
SELECT id FROM `sprint3-analytics-rcarrera1.sprint3_bronze.transactions_raw_native`;
```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda

Resultados de la consulta

Chat Guardar los resultados ▾ Abrir en ▾

Información del trabajo

Resultados

Visualización

JSON

Detalles de la ejecución

Gráfico de ejecución

|                        |                                                                                                           |
|------------------------|-----------------------------------------------------------------------------------------------------------|
| ID de trabajo          | sprint3-analytics-rcarrera1:EU.bqjob_3c45ee37_19e96e6c798 <a href="#">(Ver detalles de rendimiento ↗)</a> |
| Usuario                | roscarrera13@gmail.com                                                                                    |
| Ubicación              | EU                                                                                                        |
| Hora de creación       | 5 jun 2026, 10:29:28 a.m. UTC+2                                                                           |
| Hora de inicio         | 5 jun 2026, 10:29:28 a.m. UTC+2                                                                           |
| Hora de finalización   | 5 jun 2026, 10:29:29 a.m. UTC+2                                                                           |
| Duración               | 1 s                                                                                                       |
| Bytes procesados       | 3.62 MB                                                                                                   |
| Bytes facturados       | 10 MB                                                                                                     |
| Milisegundos de ranura | 399                                                                                                       |
| Prioridad del trabajo  | INTERACTIVE                                                                                               |
| Usar SQL heredado      | false                                                                                                     |
| Tabla de destino       | <a href="#">Tabla temporal</a>                                                                            |
| Etiquetas              |                                                                                                           |

**Observacions:** en fer la consulta d'un camp sobre la **taula nativa** observem que processa menys bytes, en aquest cas una tercera part aproximadament (3,62 MB). Tot i així es facturen 10MB ja que és la unitat mínima de facturació de BigQuery.

## » CONCLUSIONS TÈCNIQUES

### Observacions:

Ja hem dit que la consulta sobre la taula externa **processa** tres vegades més bytes que la taula nativa. Això és degut al fet que **BigQuery** no guarda les dades per files sinó per **columnnes**. Així quan fem una consulta d'un camp sobre una **taula nativa**, BigQuery només ha de processar les dades d'aquella columna. Quan es fa la consulta sobre la **taula externa** BigQuery ha d'accedir a les dades que estan guardades a **Google Cloud Storage** en format **CSV**. Per poder extreure les dades de la columna demanada ha de llegir tot el fitxer línia per línia i per tant processa més bytes.

D'altra banda veiem que els **bytes facturats** són semblants ja que BigQuery factura com a mínim 10MB per taula processada encara que en realitat s'hagin mogut menys dades. La diferència de facturació seria més significativa en taules amb més quantitat de registres.

## c) El perill del LIMIT

Molts analistes pensen que posar LIMIT 10 redueix el cost de la consulta.



Tasca:

Fes un **SELECT \* FROM transactions\_raw\_native LIMIT 10** sobre la taula nativa..



Comprovació: Mira el "Dry Run". Ha baixat el cost respecte a no posar LIMIT? Explica breument per què això és una trampa per a principiants.

### » CONSULTES SENSE LÍMIT I AMB LÍMIT

```
1  
2 SELECT * FROM `sprint3_bronze.transactions_raw_native`;  
3  
4  
-
```

✓ Esta consulta procesará 10.87 MB cuando se ejecute.

```
1  
2 SELECT * FROM `sprint3_bronze.transactions_raw_native` LIMIT 10;  
3  
4  
-
```

✓ Esta consulta procesará 10.87 MB cuando se ejecute.

**Observacions:** tant la consulta sense límit com amb límit processen el **mateix** volum de dades: 10,87MB. Això és degut al fet que internament BigQuery no guarda les dades per files sinó per **columnnes**. Així quan fem un **SELECT \*** obliguem a BigQuery a carregar en memòria totes les columnnes. Un cop carregades és quan aplica el límit i només mostra les files que li hem indicat.

## Exercici 5: Adaptació de Sintaxi (Reporting)



Tasca:


El teu cap vol saber quins van ser els 5 dies amb més ingressos de l'any 2021.



Repte:

Probablement el camp timestamp és un STRING. Hauràs d'investigar funcions de BigQuery (SUBSTR, CAST, PARSE\_TIMESTAMP) per filtrar l'any i agrupar per data correctament.

## » TAULA TRANSACTIONS\_RAW\_NATIVE



sprint3-analytics-rcarrera1 / Datasets / sprint3\_bronze / Tables / transactions\_raw\_native

☆ transactions\_r... Consulta Chat Abrir en ▾ + Compartir ▾ Copiar

Esquema Detalles Vista previa Explorador de tablas Vista previa Estadísticas Linaje

Filtro Escribir el nombre o valor de la propiedad

| <input type="checkbox"/> | Nombre del campo | Tipo      | Modo     | Descripción | Clave | Intercalación |
|--------------------------|------------------|-----------|----------|-------------|-------|---------------|
| <input type="checkbox"/> | id               | STRING    | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | card_id          | STRING    | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | business_id      | STRING    | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | timestamp        | TIMESTAMP | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | amount           | FLOAT     | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | declined         | INTEGER   | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | product_ids      | STRING    | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | user_id          | INTEGER   | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | lat              | FLOAT     | NULLABLE | -           | -     | -             |
| <input type="checkbox"/> | longitude        | FLOAT     | NULLABLE | -           | -     | -             |

**Observacions:** farem la consulta sobre la taula de **transaccions nativa** ja que processarà menys bytes i serà més ràpida. Revisem l'**esquema** de la taula (definició dels camps) i veiem que el camp **timestamp** és de tipus **TIMESTAMP** per tant no l'haurem de convertir, simplement haurem d'extreure la part que ens convingui.

## » CONSULTA

```
1
2 SELECT EXTRACT(DATE FROM t.timestamp) AS day, ROUND(SUM(t.amount),2) AS total
3 FROM `sprint3-analytics-rcarrera1.sprint3_bronze.transactions_raw_native` AS t
4 WHERE EXTRACT(YEAR FROM t.timestamp) = 2021
5 GROUP BY day
6 ORDER BY total DESC LIMIT 5;
```

✓ Se completó la consulta

Se está usando la cuota de procesamiento según demanda

### Resultados de la consulta

| Información del trabajo |            | Resultados | Visualización | JSON | Detalles de la ejecución |
|-------------------------|------------|------------|---------------|------|--------------------------|
| Fila                    | day ▼      | total ▼    |               |      |                          |
| 1                       | 2021-10-27 | 11440.81   |               |      |                          |
| 2                       | 2021-01-22 | 11328.84   |               |      |                          |
| 3                       | 2021-02-11 | 11182.16   |               |      |                          |
| 4                       | 2021-04-29 | 11119.01   |               |      |                          |
| 5                       | 2021-03-27 | 10898.51   |               |      |                          |

**Observacions:** utilitzem la funció **EXTRACT** per capturar la data i l'any del camp **timestamp**.

## Exercici 6: Consultes Complexes

Necessitem un informe que creui dades.



Tasca:

Llista el nom, país i data de les transaccions realitzades per empreses que van fer operacions entre 100 i 200 euros en alguna d'aquestes dates: 29-04-2015, 20-07-2018 o 13-03-2024.

## » CONSULTA

```
1 SELECT c.company_name, c.country, EXTRACT(DATE FROM t.timestamp) AS day
2 FROM `sprint3_bronze.transactions_raw_native` as t
3 INNER JOIN `sprint3_bronze.companies_raw` as c ON t.business_id = c.company_id
4 WHERE (t.amount BETWEEN 100 AND 200) AND (EXTRACT(DATE FROM t.timestamp) IN ('2015-04-29', '2018-07-20', '2024-03-13'))
5 ORDER BY c.company_name;
6
```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda

### Resultados de la consulta

[Chat](#)[Guardar los resultados](#)[Abrir en](#)[Información del trabajo](#)[Resultados](#)[Visualización](#)[JSON](#)[Detalles de la ejecución](#)[Gráfico de ejecución](#)

| Fila | company_name              | country        | day        |  |
|------|---------------------------|----------------|------------|--|
| 1    | Ac Libero Inc.            | United Kingdom | 2024-03-13 |  |
| 2    | Ac Libero Inc.            | United Kingdom | 2015-04-29 |  |
| 3    | Aliquam Erat Volutpat LLP | Italy          | 2024-03-13 |  |
| 4    | Aliquam Erat Volutpat LLP | Italy          | 2018-07-20 |  |
| 5    | Amet Lorem LLP            | Spain          | 2015-04-29 |  |
| 6    | At Pede Corp.             | Italy          | 2018-07-20 |  |
| 7    | Auctor Mauris Vel LLP     | United States  | 2015-04-29 |  |
| 8    | Dictum Eu Corp.           | Canada         | 2015-04-29 |  |
| 9    | Donec Fringilla PC        | France         | 2015-04-29 |  |
| 10   | Et Magnis Ltd             | Belgium        | 2018-07-20 |  |
| 11   | Fusce Corp.               | United States  | 2018-07-20 |  |
| 12   | Justo Eu Arcu Ltd         | Italy          | 2018-07-20 |  |
| 13   | Justo Eu Arcu Ltd         | Italy          | 2024-03-13 |  |
| 14   | Magna Incorporated        | New Zealand    | 2018-07-20 |  |

Bytes procesados

2.3 MB

Bytes facturados

20 MB

Resultados por página:

50

1 - 19 de 19



**Observacions:** per fer aquesta consulta enllacem dues taules: **transactions\_raw\_native** i **companies\_raw**. Tot i que es processen 2.3MB veiem que es facturen 20MB ja que la facturació mínima és de 10MB per taula processada.

## Nivell 2: Neteja i Transformació (ELT)

Escenari:

Les dades brutes tenen problemes de qualitat (símbols de moneda, usuaris duplicats, dates incorrectes). Actua com a **Data Engineer** per netejar-ho tot.

# Exercici 1: Neteja de Productes (Data Quality)



Crearem la capa neta ("Silver") per als productes. Tens la taula **sprint3\_bronze.products\_raw** carregada des del CSV. L'equip de **Data Governance** et demana crear una taula de productes neta a **sprint3\_silver.products\_clean** que compleixi aquestes regles de qualitat:

- » **Estandardització de Noms:** La columna original id és ambigua; reanomena-la a product\_id. La columna product\_name simplifica-la a name.
- » **Neteja d'IDs:** El camp warehouse\_id té el format antic "WH-4". Elimina el prefix "WH-" i converteix el valor a número enter (INT64).
- » **Garantia de Preu:** Assegura't que price és un número (FLOAT64), sense símbols de moneda.
- » **Altres columnes:** Conserva el camp weight (pes) tal qual.

### » TAULA PRODUCTS\_RAW

| ☆                                                 | products_raw     | Consulta     | Chat                 | Abrir en ▾   | Compartir ▾  | Copiar        |
|---------------------------------------------------|------------------|--------------|----------------------|--------------|--------------|---------------|
| Esquema                                           | Detalles         | Vista previa | Explorador de tablas | Vista previa | Estadísticas | Linaje        |
| Filtro Escribir el nombre o valor de la propiedad |                  |              |                      |              |              |               |
| <input type="checkbox"/>                          | Nombre del campo | Tipo         | Modo                 | Descripción  | Clave        | Intercalación |
| <input type="checkbox"/>                          | id               | INTEGER      | NULLABLE             | -            | -            | -             |
| <input type="checkbox"/>                          | product_name     | STRING       | NULLABLE             | -            | -            | -             |
| <input type="checkbox"/>                          | price            | FLOAT        | NULLABLE             | -            | -            | -             |
| <input type="checkbox"/>                          | colour           | STRING       | NULLABLE             | -            | -            | -             |
| <input type="checkbox"/>                          | weight           | FLOAT        | NULLABLE             | -            | -            | -             |
| <input type="checkbox"/>                          | warehouse_id     | STRING       | NULLABLE             | -            | -            | -             |
| <input type="checkbox"/>                          | category         | STRING       | NULLABLE             | -            | -            | -             |
| <input type="checkbox"/>                          | brand            | STRING       | NULLABLE             | -            | -            | -             |
| <input type="checkbox"/>                          | cost             | FLOAT        | NULLABLE             | -            | -            | -             |
| <input type="checkbox"/>                          | launch_date      | DATE         | NULLABLE             | -            | -            | -             |

**Observacions:** a l'esquema de la taula veiem que els camps de **preu** són de tipus **FLOAT** per tant no caldrà convertir-los.

### » CREACIÓ DE TAULA PRODUCTS\_CLEAN A LA CAPA SILVER

```
1
2
3 CREATE OR REPLACE TABLE `sprint3_silver.products_clean` AS
4 SELECT
5   id AS product_id,
6   product_name AS name,
7   CAST(REPLACE(warehouse_id, 'WH-', '') AS INT64) AS warehouse_id,
8   price, colour, weight, category, brand, cost, launch_date
9 FROM `sprint3_bronze.products_raw`;
```

✓ Se completó la consulta

Se está usando la cuota de procesamiento según demanda

#### Resultados de la consulta

Chat G

Información del trabajo

**Resultados**

Detalles de la ejecución

Gráfico de ejecución



Esta declaración creó una nueva tabla con el nombre products\_clean.

**Observacions:** utilitzem la funció **REPLACE** per substituir el prefix 'WH-' del camp **warehouse\_id** per una cadena buida. Després convertim a enter amb la funció **CAST**.

## » COMPROVACIÓ DE LES DADES

| ☆       | products_clean | Consulta           | Chat                 | Abrir en ▾   | Compartir ▾  | Copiar | Instantánea     | Borrar               | ↑     |             |
|---------|----------------|--------------------|----------------------|--------------|--------------|--------|-----------------|----------------------|-------|-------------|
| Esquema | Detalles       | Vista previa       | Explorador de tablas | Vista previa | Estadísticas | Linaje | Perfil de datos | Calidad de los datos |       |             |
| Fila    | product_id     | name               | warehouse_id         | price        | colour       | weight | category        | brand                | cost  | launch_date |
| 1       | 48             | rock Renly in      | 43                   | 21.53        | #9e9e9e      | 2.1    | Beauty          | Bloom                | 7.38  | 2014-07-24  |
| 2       | 97             | jinn Winterfell    | 92                   | 65.25        | #bababa      | 1.0    | Beauty          | CareLab              | 26.25 | 2013-02-22  |
| 3       | 90             | Winterfell         | 85                   | 39.73        | #757575      | 0.8    | Beauty          | CareLab              | 16.58 | 2013-11-01  |
| 4       | 96             | dooku solo         | 91                   | 20.92        | #282828      | 2.1    | Beauty          | CareLab              | 8.75  | 2013-09-21  |
| 5       | 18             | Karstark warden    | 13                   | 148.91       | #c4c4c4      | 0.8    | Beauty          | CareLab              | 47.62 | 2013-07-11  |
| 6       | 28             | chewbacca mustafar | 23                   | 127.44       | #efefef      | 3.0    | Beauty          | Luma Skin            | 45.65 | 2014-06-02  |
| 7       | 42             | sith               | 37                   | 83.51        | #494949      | 0.8    | Beauty          | Luma Skin            | 27.23 | 2013-06-10  |
| 8       | 25             | skywalker ewok     | 20                   | 157.53       | #2b2b2b      | 1.0    | Beauty          | Luma Skin            | 53.56 | 2014-04-22  |
| 9       | 66             | mustafar jinn      | 61                   | 2.12         | #545454      | 0.8    | Books           | Atlas Books          | 1.1   | 2014-02-12  |

**Observacions:** comprovem que hem canviat els noms dels camps indicats i que el camp **warehouse\_id** té el format indicat.

## Exercici 2: Creació de Transaccions Netes (Capa Silver)



Tasca:

La taula **transactions\_raw** (Bronze) és insegura: l'import (amount) podria tenir lletres, les coordenades podrien fallar i la data és un text difícil de filtrar. Crearem la taula definitiva **sprint3\_silver.transactions\_clean** que garanteixi el següent.

- » **Estandardització de Noms:** La columna original id és ambigua; reanomena-la a transaction\_id.
- » **Robustesa en Imports:** Utilitza SAFE\_CAST al camp amount. Si falla, substitueix-lo per 0 (usant IFNULL).
- » **Dates Reals:** Converteix el camp timestamp (que és STRING) a tipus TIMESTAMP real.
- » **Coordenades:** Assegura que lat i longitude siguin FLOAT64 (utilitza SAFE\_CAST per seguretat).
- » **Desglòs de Productes:** Transforma la cadena de text product\_ids en un ARRAY d'enters.
  - Input: "1, 2, 3" (String)
  - Output: [1, 2, 3] (Array/Llista d'enters)
- » **Resta de camps:** Mantén-los igual.

### » CREACIÓ DE LA TAULA TRANSACTIONS\_CLEAN

```
1
2 CREATE OR REPLACE TABLE `sprint3_silver.transactions_clean` AS
3 SELECT
4     id AS transaction_id,
5     card_id,
6     business_id,
7     SAFE_CAST(timestamp AS TIMESTAMP) AS timestamp,
8     IFNULL(SAFE_CAST(amount AS FLOAT64), 0.0) AS amount,
9     declined,
10    ARRAY(
11        SELECT SAFE_CAST(p_id AS INT64)
12        FROM UNNEST(SPLIT(product_ids, ',')) AS p_id
13    ) AS product_ids,
14    user_id,
15    IFNULL(SAFE_CAST(lat AS FLOAT64), 0.0) AS lat,
16    IFNULL(SAFE_CAST(longitude AS FLOAT64), 0.0) AS longitude,
17 FROM `sprint3_bronze.transactions_raw`;
18
```

✓ Se completó la consulta

Resultados de la consulta

Chat

Guardar los resultados ▾

Al

Información del trabajo

**Resultados**

Detalles de la ejecución

Gráfico de ejecución



Esta declaración creó una nueva tabla con el nombre transactions\_clean.

#### Observacions:


**SPLIT** : converteix el text del camp **product\_ids** a una llista de textos → ['25','69','12']

**UNNEST** : genera una fila per cadascun dels elements de la llista.

**SAFE\_CAST**: converteix a enter cadascun dels elements.

**ARRAY**: converteix les files en una llista que ara serà una llista d'enters.

### » COMPROVACIÓ DE L'ESQUEMA DE LA TAULA TRANSACTIONS\_CLEAN



sprint3-analytics-rcarrera1 / Datasets / sprint3\_silver / Tables / transactions\_clean

☆ transactions\_... Consulta Chat Abrir en ▾ + Compartir ▾

Esquema Detalles Vista previa Explorador de tablas Vista previa Estadísticas

Filtro Escribir el nombre o valor de la propiedad

| <input type="checkbox"/> | Nombre del campo | Tipo      | Modo     | Descripción | Clave | Ir |
|--------------------------|------------------|-----------|----------|-------------|-------|----|
| <input type="checkbox"/> | transaction_id   | STRING    | NULLABLE | -           | -     | -  |
| <input type="checkbox"/> | card_id          | STRING    | NULLABLE | -           | -     | -  |
| <input type="checkbox"/> | business_id      | STRING    | NULLABLE | -           | -     | -  |
| <input type="checkbox"/> | timestamp        | TIMESTAMP | NULLABLE | -           | -     | -  |
| <input type="checkbox"/> | amount           | FLOAT     | NULLABLE | -           | -     | -  |
| <input type="checkbox"/> | declined         | INTEGER   | NULLABLE | -           | -     | -  |
| <input type="checkbox"/> | product_ids      | INTEGER   | REPEATED | -           | -     | -  |
| <input type="checkbox"/> | user_id          | INTEGER   | NULLABLE | -           | -     | -  |
| <input type="checkbox"/> | lat              | FLOAT     | NULLABLE | -           | -     | -  |
| <input type="checkbox"/> | longitude        | FLOAT     | NULLABLE | -           | -     | -  |

**Observacions:** el camp **product\_ids** és de tipus **INTEGER** i mode **REPEATED**. Aquesta és la manera com es defineixen els **ARRAYS** a BigQuery.

## » VISTA PRÈVIA DE LES DADES DE TRANSACTIONS\_CLEAN

sprint3-analytics-rcarrera1 / Datasets / sprint3\_silver / Tables / transactions\_clean

☆ transactions\_...

🔍 Consulta

💬 Chat

Abrir en ▾

+👤 Compartir ▾

📄 Copiar

📄 Instantànea

🗑️

⬆️

🔄

Esquema

Detalles

Vista previa

Explorador de tablas

Vista previa

Estadísticas

Linaje

Perfil de datos

Calidad de los datos

| Fila | transaction_id                | card_id  | business_id | timestamp               | amount | declined | product_ids | user_id | lat           | longitude      |
|------|-------------------------------|----------|-------------|-------------------------|--------|----------|-------------|---------|---------------|----------------|
| 1    | 00D8F1C6-FF88-4E47-B26B-BC... | CcU-4856 | b-2314      | 2022-01-25 22:57:15 UTC | 272.45 | 0        | 81          | 1       | 40.7174604... | -73.9960221... |
|      |                               |          |             |                         |        |          | 94          |         |               |                |
|      |                               |          |             |                         |        |          | 95          |         |               |                |
|      |                               |          |             |                         |        |          | 66          |         |               |                |
|      |                               |          |             |                         |        |          | 64          |         |               |                |
| 2    | 6ED484BC-2DBB-47CF-B77E-12... | CcU-4856 | b-2242      | 2015-05-08 18:09:41 UTC | 233.52 | 0        | 85          | 1       | 40.7188407... | -74.0131030... |
|      |                               |          |             |                         |        |          | 56          |         |               |                |
|      |                               |          |             |                         |        |          | 55          |         |               |                |

**Observacions:** observem com ha canviat el format del camp **product\_ids**. Abans era tipus **STRING** i ara és un array d'enters (**INTEGER REPEATED**)

| product_ids    |
|----------------|
| 40, 47, 56     |
| 76, 87         |
| 64, 74, 52, 22 |
| 26, 14, 70, 37 |

## Exercici 3: Unificació d'Usuaris (UNION)

Tenim els usuaris fragmentats per regió.



Tasca:

Crea la taula **sprint3\_silver.users\_combined**. Utilitza **UNION ALL** per unificar els usuaris dels EUA i Europa en una única llista mestra. Afegeix una columna calculada **origin** per saber d'on venen.

» **Estandardització de Noms:** La columna original **id** és ambigua; reanomena-la a **user\_id**.

### » CREACIÓ DE LA TAULA USERS\_COMBINED

```
1
2 CREATE OR REPLACE TABLE `sprint3_silver.users_combined` AS
3 SELECT
4   id AS user_id,
5   'USA' AS origin,
6   name, surname, phone, email, birth_date, country, city, postal_code, address
7 FROM `sprint3_bronze.american_users_raw`
8 UNION ALL
9 SELECT
10  id AS user_id,
11  'EU' AS origin,
12  name, surname, phone, email, birth_date, country, city, postal_code, address
13 FROM `sprint3_bronze.european_users_raw`;
14
15
```

✓ Se completó la consulta

#### Resultados de la consulta

[Chat](#)[Guarda](#)[Información del trabajo](#)[Resultados](#)[Detalles de la ejecución](#)[Gráfico de ejecución](#)

Esta declaración creó una nueva tabla con el nombre users\_combined.

**Observacions:** en fer l'unió de les dues taules creem també un nou camp: **origin**. Aquest camp pren el valor **'USA'** pels registres de la taula **american\_users\_raw** i **'EU'** pels registres de la taula **european\_users\_raw**.

## » VISTA PRÈVIA DE LA TAULA USERS\_COMBINED

sprint3-analytics-rcarrera1 / Datasets / sprint3\_silver / Tables / **users\_combined**

☆ users\_combin... [Consulta](#) [Chat](#) [Abrir en ▾](#) [Compartir ▾](#) [Copiar](#) [Instantánea](#) [🗑️](#) [↑](#) [↺](#)

Esquema Detalles **Vista previa** Explorador de tablas **Vista previa** Estadísticas Linaje Perfil de datos Calidad de los datos

| Fila | user_id | origin | name   | surname  | phone          | email                        | birth_date   | country         | city       |
|------|---------|--------|--------|----------|----------------|------------------------------|--------------|-----------------|------------|
| 4472 | 3295    | EU     | Mkyihf | Nfjowjyy | +46-182-2171   | mkyihf.nfjowjyy@example.com  | Jul 26, 1993 | United Kingd... | Manchester |
| 4473 | 3698    | EU     | Rqawnv | Bezumbzi | +67-201-6151   | rqawnv.bezumbzi@example.com  | Nov 23, 1969 | United Kingd... | Manchester |
| 4474 | 4942    | EU     | Ypdqje | Zmsionmq | +88-416-6277   | ypdqje.zmsionmq@example.com  | Aug 16, 1997 | United Kingd... | Manchester |
| 4475 | 922     | EU     | Yzvboe | Pfbsuzsq | +75-280-6837   | yzvboe.pfbsuzsq@example.com  | Aug 11, 1966 | United Kingd... | Manchester |
| 4476 | 1416    | EU     | Fuydro | Cbqzkzui | +92-362-6921   | fuydro.cbqzkzui@example.com  | Sep 15, 1957 | United Kingd... | Manchester |
| 4477 | 155     | EU     | Joshua | Russell  | 055 4409 5286  | justo.nec.ante@outlook.edu   | Jan 23, 1984 | United Kingd... | Manchester |
| 4478 | 613     | EU     | Qcazdy | Jaqxbzjn | +63-181-4449   | qcazdy.jaqxbzjn@example.com  | Feb 1, 1994  | United Kingd... | Manchester |
| 4479 | 3463    | EU     | Azzflk | Womvxnak | +70-797-7763   | azzflk.womvxnak@example.com  | Dec 4, 1969  | United Kingd... | Manchester |
| 4480 | 4930    | EU     | Ogwadp | Qmqsnxip | +54-950-6676   | ogwadp.qmqsnxip@example.c... | Nov 13, 1965 | United Kingd... | Manchester |
| 4481 | 1983    | USA    | Fkqpqm | Cfktqwws | +89-858-3317   | fkqpqm.cfktqwws@example.com  | Jan 21, 1984 | United States   | New York   |
| 4482 | 117     | USA    | Halla  | Pearson  | (681) 698-7518 | lacus.etiam@protonmail.couk  | Apr 19, 1994 | United States   | New York   |
| 4483 | 673     | USA    | Iasjuo | Lvbgnjel | +38-265-9113   | iasjuo.lvbgnjel@example.com  | Mar 17, 1996 | United States   | New York   |
| 4484 | 1725    | USA    | Svvybq | Zwjuoine | +30-948-9086   | svvybq.zwjuoine@example.com  | Dec 6, 1985  | United States   | New York   |
| 4485 | 28      | USA    | Elmo   | Cain     | 1-663-583-6021 | nec.metus.facilis@google.org | Oct 13, 1980 | United States   | New York   |

**Observacions:** comprovem els canvis que hem fet.

# Exercici 4: Materialització de Companyies i Targetes de Crèdit

Escenari:

Per completar el model de dades a la capa **Silver**, ens falten dues dimensions clau que actualment depenen de fitxers CSV externs: **Companyies** i **Targetes de Crèdit**. No podem dependre de fitxers solts per a l'anàlisi final. Hem d'importar aquestes dades a taules natives (Silver) i aprofitar per corregir formats.



Tasques:

- » 1. Crea la taula **sprint3\_silver.companies\_clean**. Copia les dades tal qual, però assegura't que sigui una taula nativa de BigQuery (no una vista externa).
- » 2. Crea la taula **sprint3\_silver.credit\_cards\_clean**. Copia les dades tal qual, però assegura't que sigui una taula nativa de BigQuery (no una vista externa).

Si cal, reanomenar l'id segons correspongui.

## » CREACIÓ DE LA TAULA COMPANIES\_CLEAN

```
1
2 CREATE OR REPLACE TABLE `sprint3_silver.companies_clean` AS
3 SELECT *
4 FROM `sprint3_bronze.companies_raw`;
5
6
7
```

✓ Se completó la consulta

Resultados de la consulta

Chat

Información del trabajo

**Resultados**

Detalles de la ejecución

Gráfico de ejecución

**i** Esta declaración creó una nueva tabla con el nombre companies\_clean.

**Observacions:** utilitzem **CREATE OR REPLACE TABLE** per tal de crear una taula nativa.

A la dreta veiem que la taula origen **companies\_raw** ja té ben identificat el camp d'**id**, per tant no cal fer cap canvi. Podem fer un **SELECT \*** per tal de copiar tots els camps amb la mateixa configuració.

☆ companies\_raw

🔍 Consulta

💬 Chat

📄 Abrir en ▾

👤 Compartir ▾

Esquema

Detalles

Estadísticas

Linaje

Perfil de datos

Calidad de los datos

🔍 Filtro Escribir el nombre o valor de la propiedad

| <input type="checkbox"/> | Nombre del campo | Tipo   | Modo     | Descripción | Clave | Intercala |
|--------------------------|------------------|--------|----------|-------------|-------|-----------|
| <input type="checkbox"/> | company_id       | STRING | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | company_name     | STRING | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | phone            | STRING | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | email            | STRING | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | country          | STRING | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | website          | STRING | NULLABLE | -           | -     | -         |

## » CREACIÓ DE LA TAULA CREDIT\_CARDS\_CLEAN

```

1
2 CREATE OR REPLACE TABLE `sprint3_silver.credit_cards_clean` AS
3 SELECT
4   id AS card_id, user_id, iban, pan, pin, cvv, track1, track2, expiring_date
5 FROM `sprint3_bronze.credit_cards_raw`;
6
7

```

✓ Se completó la consulta

### Resultados de la consulta

Información del trabajo

**Resultados**

Detalles de la ejecución

Gráfico de ejecución

**i** Esta declaración creó una nueva tabla con el nombre credit\_cards\_clean.

**Observacions:** en aquest cas cal canviar el nom del camp **id** per això cal identificar tots els camps a la consulta. A la dreta veiem l'esquema de la taula final **credit\_cards\_clean** on es mostra que el nom del camp ha canviat.

sprint3-analytics-rcarrera1 / Datasets / sprint3\_silver / Tables / **credit\_cards\_clean**

☆ credit\_cards\_... 🔍 Consulta 🗨 Chat 📄 Abrir en ▾ 👤 Compartir ▾

Esquema Detalles Vista previa Explorador de tablas **Vista previa** Estadísticas

🔍 Filtro Escribir el nombre o valor de la propiedad

| <input type="checkbox"/> | Nombre del campo | Tipo    | Modo     | Descripción | Clave | Intervalo |
|--------------------------|------------------|---------|----------|-------------|-------|-----------|
| <input type="checkbox"/> | card_id          | STRING  | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | user_id          | INTEGER | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | iban             | STRING  | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | pan              | STRING  | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | pin              | INTEGER | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | cvv              | INTEGER | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | track1           | STRING  | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | track2           | STRING  | NULLABLE | -           | -     | -         |
| <input type="checkbox"/> | expiring_date    | DATE    | NULLABLE | -           | -     | -         |

# Nivell 3: Presentació de Dades i Creació de Vistes

Escenari:

Al nivell anterior vas actuar com a **Data Engineer** netejant les dades (\_clean). Ara toca posar-se el barret d'**Analista de Negoci**. El problema actual és que les taules estan separades i algunes tenen formats difícils d'explotar (com la llista de productes comprimida en una sola cel·la). En aquest nivell crearàs **Vistes** per facilitar l'accés a la informació i generaràs **informes** finals.

# Exercici 1: La Vista de Màrqueting (Lògica de Negoci)

Màrqueting necessita segmentar els clients corporatius, però no saben fer JOINS. La teva tasca és deixar-los la informació preparada.



Tasca:

Crea una vista anomenada **sprint3\_gold.v\_marketing\_kpis** que mostri la següent informació per a cada companyia:

- » Nom de la companyia, Telèfon i País (origen: companies\_clean).
- » Mitjana de compra (AVG(amount) de transactions\_clean).
- » Classificació de Client (Lògica):
  - Crea una columna calculada anomenada client\_tier.
  - Si la mitjana de compra és superior a 260€, etiqueta com a "Premium".
  - Si és igual o inferior, etiqueta com a "Standard".



Entrega:

Realitza una consulta SELECT \* sobre la teva nova vista, ordenant els resultats perquè apareguin primer els clients "Premium" i, dins d'aquests, els que tinguin major mitjana de compra.

## » CREACIÓ DE LA VISTA

```
1
2 CREATE OR REPLACE VIEW `sprint3_gold.v_marketing_kpis` AS
3   SELECT c.company_name, c.phone, c.country, ROUND(AVG(t.amount),2) AS avg_amount,
4         CASE WHEN AVG(t.amount) > 260 THEN 'Premium' ELSE 'Standard' END AS client_tier
5   FROM `sprint3_silver.companies_clean` AS c
6   INNER JOIN `sprint3_silver.transactions_clean` AS t ON c.company_id = t.business_id
7   GROUP BY c.company_name, c.phone, c.country;
8
~
```

✓ Se completó la consulta

### Resultados de la consulta

[Chat](#)[Guardar](#)[Información del trabajo](#)[Resultados](#)[Detalles de la ejecución](#)[Gráfico de ejecución](#)

Esta declaración reemplazó una nueva vista denominada v\_marketing\_kpis.

## » CONSULTA SOBRE LA VISTA

```
1
2 SELECT *
3 FROM `sprint3_gold.v_marketing_kpis`
4 ORDER BY client_tier, avg_amount DESC;
5
6
```

✓ Se completó la consulta

Se está usando la cuota de procesamiento según demanda

### Resultados de la consulta

[Chat](#)[Guardar los resultados ▾](#)[Ab](#)

| Información del trabajo |                               | Resultados     | Visualización | JSON         | Detalles de la ejecución | Gráfico de ejecución |
|-------------------------|-------------------------------|----------------|---------------|--------------|--------------------------|----------------------|
| Fila                    | company_name ▾                | phone ▾        | country ▾     | avg_amount ▾ | client_tier ▾            |                      |
| 1                       | Ac Fermentum Incorporated     | 06 85 56 52 33 | Germany       | 284.87       | Premium                  |                      |
| 2                       | Pretium Neque Corp.           | 07 77 48 55 28 | Australia     | 276.16       | Premium                  |                      |
| 3                       | Urna Convallis Associates     | 06 01 24 77 04 | United States | 274.24       | Premium                  |                      |
| 4                       | At Associates                 | 09 56 61 10 65 | New Zealand   | 272.21       | Premium                  |                      |
| 5                       | Metus Vitae Associates        | 08 25 44 40 66 | Australia     | 270.08       | Premium                  |                      |
| 6                       | Aliquet Diam Limited          | 02 76 61 47 46 | United States | 269.6        | Premium                  |                      |
| 7                       | Nec Luctus LLC                | 02 14 71 75 73 | Norway        | 268.6        | Premium                  |                      |
| 8                       | Neque Tellus Incorporated     | 04 43 18 34 19 | Ireland       | 267.85       | Premium                  |                      |
| 9                       | Tortor Nunc Commodore Company | 05 35 92 77 16 | United States | 267.84       | Premium                  |                      |
| 10                      | Cras Consulting               | 07 50 10 85 63 | Belgium       | 267.44       | Premium                  |                      |

# Exercici 2: Rànquing de Productes

## (La Potència dels Arrays)

Escenari de Negoci:

L'equip de vendes vol optimitzar el catàleg. Necessiten un informe a la capa Gold que mostri el rendiment real de cada producte. Gràcies a la teva bona enginyeria a la capa Silver, la taula `transactions_clean` ja té els IDs de producte perfectament organitzats en una llista (Array). Ara toca explotar aquesta estructura.

 Objectiu:

Crea la taula **`sprint3_gold.product_sales_ranking`** que contingui l'inventari complet de productes i quantes vegades s'ha venut cadascun.

 Requisits de l'Informe:

- » Detall del Producte: Ha d'incloure `product_id`, `name`, `price` i `color` (vénen de la taula `products_clean`).
- » Mètrica de Negoci: Una columna nova `total_sold` que compti quantes vegades apareix aquest producte a les transaccions.
- » Integritat: Han d'aparèixer tots els productes, fins i tot els que tenen 0 vendes (potser cal descatalogar-los).

### » CREACIÓ DE LA TAULA

```
1
2 CREATE OR REPLACE TABLE `sprint3_gold.product_sales_ranking` AS
3 WITH product_sales AS (
4   SELECT transaction_id, product_id
5     FROM `sprint3_silver.transactions_clean`,
6     UNNEST(product_ids) AS product_id
7 )
8 SELECT p.product_id, p.name, p.price, p.colour, COUNT(ps.transaction_id) AS total_sold
9   FROM `sprint3_silver.products_clean` as p
10  LEFT JOIN product_sales as ps ON ps.product_id = p.product_id
11  GROUP BY p.product_id, p.name, p.price, p.colour;
12
13
14
```

✓ Se completó la consulta

Se está usando la cuota de procesamiento según demanda

#### Resultados de la consulta

Chat

Guardar los re

Información del trabajo

**Resultados**

Detalles de la ejecución

Gráfico de ejecución



Esta declaración creó una nueva tabla con el nombre product\_sales\_ranking.

**Observacions:** Utilitzem una **CTE** amb la subconsulta **product\_sales** que genera una fila per cada valor de l'array de **product\_ids**. Per fer això utilitzem la funció **UNNEST**.

En la consulta principal enllacem la taula de productes amb aquesta subconsulta i així podem comptar quantes vegades s'ha venut cadascun.

## » VISTA PRÈVIA DE LA TAULA PRODUCT\_SALES\_RANKING

sprint3-analytics-rcarrera1 / Datasets / sprint3\_gold / Tables / **product\_sales\_ranking**

☆ product\_sales... Consulta Chat Abrir en ▾ + Compartir ▾ Copiar Insta

Esquema Detalles **Vista previa** Explorador de tablas Vista previa Estadísticas Linaje Perfil c

| fila | product_id | name                | price  | colour  | total_sold |
|------|------------|---------------------|--------|---------|------------|
| 1    | 80         | Tarly Stark         | 14.1   | #020202 | 2496       |
| 2    | 40         | tatooine dooku solo | 73.31  | #070707 | 2488       |
| 3    | 32         | north               | 178.28 | #0f0f0f | 2561       |
| 4    | 4          | warden south duel   | 71.89  | #111111 | 2584       |
| 5    | 29         | Tully maester Tarly | 167.2  | #111111 | 2635       |
| 6    | 86         | Stark kingsblood    | 189.21 | #141414 | 2528       |
| 7    | 11         | Karstark Dorne      | 49.7   | #141414 | 2573       |
| 8    | 33         | duel warden         | 127.09 | #191919 | 2597       |
| 9    | 67         | Winterfell          | 195.94 | #1c1c1c | 2552       |
| 10   | 99         | the duel            | 151.78 | #212121 | 2514       |
| 11   | 51         | north Tully         | 30.14  | #262626 | 2466       |
| 12   | 96         | dooku solo          | 20.92  | #282828 | 2506       |

## Exercici 3: Exportació de Resultats

El teu mànager no té accés a BigQuery i vol el llistat de "Top Productes" en un Excel per a una reunió.



Tasca:

Exporta les dades de la taula **product\_sales\_ranking** a Google Sheets o baixa l'arxiu CSV localment.



Entrega:

Una captura de pantalla on es vegi l'arxiu obert (Excel/Sheets) amb les dades correctament formatades.

## » PROCÉS EXPORTACIÓ

The screenshot shows the BigQuery web interface. At the top, there's a search bar and a tab labeled '\*Consult...ulo'. Below the search bar, the query editor shows a SQL query: `SELECT * FROM `sprint3_gold.product_sales_ranking` ORDER BY total_sold DESC;`. The query has been executed, and a message states 'Se completó la consulta' and 'Se está usando la cuota de procesamiento según demanda'. Below the query editor, the 'Resultados de la consulta' section is active, showing a table with 9 rows and 5 columns: product\_id, name, price, colour, and an unlabeled column. The table is sorted by price in descending order. On the right side, a dropdown menu is open, showing options for exporting the data: 'Copiar en el portapapeles hasta 1 MB', 'Google Drive CSV hasta 1 GB', 'JSONL (delimitado por líneas nuevas) hasta 1 GB', 'Hojas de cálculo de Google hasta 10 MB', 'Descarga local CSV hasta 10 MB', 'JSON hasta 10 MB', 'Google Cloud Cloud Storage', and 'Tabla de BigQuery'.

Buscar (/) recursos, documentos, productos y más

Consulta sin título Ejecutar Guardar Descargar Compartir

```
1 SELECT *
2 FROM `sprint3_gold.product_sales_ranking`
3 ORDER BY total_sold DESC;
```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda

Resultados de la consulta Chat

Información del trabajo Resultados Visualización JSON Detalles de la ejecución

| Fila | product_id | name                | price  | colour  |      |
|------|------------|---------------------|--------|---------|------|
| 1    | 52         | riverlands the duel | 31.52  | #727272 | 2609 |
| 2    | 29         | Tully maester Tarly | 167.2  | #111111 | 2635 |
| 3    | 21         | duel Direwolf       | 96.9   | #e2e2e2 | 2609 |
| 4    | 16         | the duel warden     | 180.91 | #666666 | 2608 |
| 5    | 66         | mustafar jinn       | 2.12   | #545454 | 2601 |
| 6    | 87         | sith Jade           | 96.26  | #e2e2e2 | 2598 |
| 7    | 48         | rock Renly in       | 21.53  | #9e9e9e | 2597 |
| 8    | 33         | duel warden         | 127.09 | #191919 | 2597 |
| 9    | 23         | riverlands north    | 169.96 | #545454 | 2593 |

Copiar en el portapapeles hasta 1 MB

Google Drive CSV hasta 1 GB

JSONL (delimitado por líneas nuevas) hasta 1 GB

Hojas de cálculo de Google hasta 10 MB

Descarga local CSV hasta 10 MB

JSON hasta 10 MB

Google Cloud Cloud Storage

Tabla de BigQuery

**Observacions:** ordenem els registres de la taula **product\_sales\_ranking** pel camp **total\_sold** de forma descendent i així els tenim ordenats de més a menys venuts.

## » FULL DE CàLCUL

product\_sales\_ranking ☆ 📁 ☁

Fitxer Edita Mostra Insereix Format Dades Eines Extensions Ajuda

🔍 ↶ ↷ 🖨 📋 100% ▼ € % 0.00 123 Predet... ▼ - 10 + B I 🔍 A 📌 📊 📈

128 ▼ fx

|    | A          | B                    | C      | D       | E          | F | G |
|----|------------|----------------------|--------|---------|------------|---|---|
| 1  | product_id | name                 | price  | colour  | total_sold |   |   |
| 2  | 52         | riverlands the duel  | 31,52  | #727272 | 2654       |   |   |
| 3  | 29         | Tully maester Tary   | 167,2  | #111111 | 2635       |   |   |
| 4  | 21         | duel Direwolf        | 96,9   | #e2e2e2 | 2609       |   |   |
| 5  | 16         | the duel warden      | 180,91 | #666666 | 2608       |   |   |
| 6  | 66         | mustafar jinn        | 2,12   | #545454 | 2601       |   |   |
| 7  | 87         | sith Jade            | 96,26  | #e2e2e2 | 2598       |   |   |
| 8  | 48         | rock Renly in        | 21,53  | #9e9e9e | 2597       |   |   |
| 9  | 33         | duel warden          | 127,09 | #191919 | 2597       |   |   |
| 10 | 23         | riverlands north     | 169,96 | #545454 | 2593       |   |   |
| 11 | 68         | Stark Karstark       | 167,37 | #333333 | 2589       |   |   |
| 12 | 88         | Stannis warden south | 167,15 | #515151 | 2587       |   |   |
| 13 | 28         | chewbacca mustafar   | 127,44 | #efefef | 2584       |   |   |
| 14 | 4          | warden south duel    | 71,89  | #111111 | 2584       |   |   |
| 15 | 73         | Dorne bastard        | 114,09 | #848484 | 2584       |   |   |
| 16 | 34         | of north             | 128,48 | #919191 | 2580       |   |   |
| 17 | 31         | Lannister            | 85,02  | #3f3f3f | 2580       |   |   |
| 18 | 38         | ewok sith            | 55,43  | #666666 | 2578       |   |   |
| 19 | 61         | Winterfell Lannister | 28,01  | #848484 | 2575       |   |   |
| 20 | 36         | Lannister            | 96,22  | #a5a5a5 | 2575       |   |   |
| 21 | 54         | dooku solo           | 13,14  | #e5e5e5 | 2575       |   |   |
| 22 | 24         | south duel tourney   | 48,99  | #aaaaaa | 2574       |   |   |
| 23 | 2          | Tary Stark           | 9,24   | #919191 | 2573       |   |   |
| 24 | 72         | north                | 161,6  | #474747 | 2573       |   |   |